

Northeastern University



tm



- R text mining library
- install.packages('tm")
- library(tm)

Load hindi text & remove punctuation



- Assume hindi.txt contains Unicode for poem in hindi
 - Contained in RStudio Session folder
- n + <- Corpus(VectorSource(readLines("hindi.txt", n=1, encoding="UTF-8")))

```
<<SimpleCorpus>>
Metadata: corpus specific: 1, document level (indexed): 0
Content: documents: 1

[1] साजन! होलीआईहै!, सुखसेहँसना, जीभरगाना, मस्तीसेमनकोबहलाना, पर्वहोगयाआज-, साजन! होलीआ ईहै!, हँसानेहमकोआईहै!
> h <- tm_map(h, removePunctuation)
> inspect(h)
<<SimpleCorpus>>
Metadata: corpus specific: 1, document level (indexed): 0
Content: documents: 1
```

[1] साजनहोलीआई हैसुखसेहँसनाजीभरगानामस्तीसेमनकोबहलानापर्वहोगयाआजसाजनहोलीआई हैहँसानेहम

कोआई है

> inspect(h)

Removing stopwords from hindi frame



```
> inspect(h)
<<SimpleCorpus>>
Metadata: corpus specific: 1, document level (indexed): 0
          documents: 1
Content:
   साजनहोलीआई हैसुखसेहँसनाजीभरगानामस्तीसेमनकोबहलानापर्वहोगयाआजसाजनहोलीआई हैहँसानेहम
> h <- tm_map(h, removeWords, c("साजनहोलीआई", "email"))
> inspect(h)
<<SimpleCorpus>>
Metadata: corpus specific: 1, document level (indexed): 0
Content: documents: 1
     हैसुखसेहँसनाजीभरगानामस्तीसेमनकोबहलानापर्वहोगयाआजसाजनहोलीआई हैहँसानेहमकोआई है
```